词法KAT作用幺半群

- 作者：GaoZheng

- 日期：2025-09-26
- 版本：v1.0.0

摘要

介绍 Kleene Algebra with Tests（KAT）与相关闭包/半环结构在本项目中的角色：用以建模可验证控制流、停机点与合规模式。提供从数学结构到工程接口的映射规范，支撑规则检查、代价累积与策略约束的统一表达。

词法KAT作用幺半群（$\mathbb{M}_{\text{Lex-KAT}} := (\mathrm{End}(\Sigma^*), \circ, \mathrm{id})$，由左/右乘子、投影族、tests 与闭包算子生成，作用于自由幺半群 $(\Sigma^*, \circ, \varepsilon)$）。下面给出该 **幺半群视角** 下的算子谱系：把底层串空间视为自由幺半群 $(\Sigma^*, \circ, \varepsilon)$，把一切“历史拓扑/预测拓扑/裁剪与匹配”做成该空间上的**端算子（End(Σ^*)**，以“函数合成”作为上层运算。先列**基本算子**，再列**复合算子**与**可用等式法则**，便于工程侧做融合与优化。

- **自由幺半群**：$M = (\Sigma^*, \circ, \varepsilon)$（串连接、空串）。
- **端算子幺半群**：$(\mathrm{End}(\Sigma^*),\ \circ\_\mathrm{func},\ \mathrm{id})$（以**函数合成**为乘法）。
- **长度与前缀偏序**：$|s|$，$x \preceq y \iff x$ 是 y 的前缀。
- **参数集合**：词典 $\mathcal{C} \subset \Sigma^*$，长度集 $U \subset \mathbb{N}$，历史步长上限 N，预测上限 L_p。

---

1) 基本算子（End$\left(\Sigma^*\right)$ 的“元器件”）

1.1 左/右乘子（来自自由幺半群的左/右作用）

- **左乘子**（历史左扩的母形）：$\mathbf{L}_h(s) = h \circ s$，$h \in \Sigma^*$。
  合成律：$\mathbf{L}_{h_1} \circ \_\mathrm{func} \mathbf{L}_{h_2} = \mathbf{L}_{h_1 \circ h_2}$，单位元 $\mathbf{L}_\varepsilon = \mathrm{id}$。
- **右乘子**（预测延展的母形）：$\mathbf{R}_h(s) = s \circ h$。
  合成律：$\mathbf{R}_{h_1} \circ \_\mathrm{func} \mathbf{R}_{h_2} = \mathbf{R}_{h_2 \circ h_1}$（**反序**拼接）。

> 这两类算子给出 M 对自身的**左右作用**，是一切“拼接/延长”的代数基元。

1.2 裁剪/投影族（幂等带）

- **尾裁剪**：$\mathbf{\Pi}_L(s) = \mathrm{tail}(s, L)$。
  幂等：$\mathbf{\Pi}_L \circ \_\mathrm{func}\mathbf{\Pi}_M = \mathbf{\Pi}_{\min(L,M)}$（可交换、可并）。
- **首裁剪**：$\mathbf{Head}_L(s) = \mathrm{prefix}(s, L)$。
  同上为幂等可交换族。
- **CJK 过滤/清洗**：$\mathbf{CJK}(s)$（非 CJK 清除/映射），亦幂等。

> 这些投影族各自构成**交换幂等半群（band）**，与 $(\mathbb{N}, \min)$ 同构。

1.3 测试/掩码（KAT 的 test）

- **后缀命中测试**：$\mathbf{T}^{\mathrm{Suf}}_{L,\mathcal{C}}(s) = \begin{cases} s, & \mathrm{tail}(s, L) \in \mathcal{C} \\ \bot, & \text{否则} \end{cases}$
- **前缀命中测试**：$\mathbf{T}^{\mathrm{Pref}}_{L,\mathcal{C}}$ 同理。
- **合法字符/预算测试**：$\mathbf{T}_{\mathrm{legal}}$、$\mathbf{T}_{\mathrm{budget}}$（条件成立留 s，否则 $\bot$）。

> tests **幂等且可交换**：$\mathbf{T}_P \circ \_\mathrm{func}\mathbf{T}_Q = \mathbf{T}_{P \wedge Q}$。

1.4 去重/规范化

- **首位去重**：$\mathbf{D}_{\mathrm{head}}(s)$（如“辑辑…”→“辑…”），幂等：$\mathbf{D} \circ \mathbf{D} = \mathbf{D}$。

---

2) 闭包与迭代算子（“命中即停/直到命中”）

2.1 历史前缀闭包（左扩直到命中或步尽）

- **定义**：
  $\mathbf{Cl}^{\mathrm{Pref}}_{U,N}(s) =$ 在 $\{\mathbf{L}_h\}$ 可用集合内迭代左乘，遇 $\exists L \in U$：$\mathbf{T}^{\mathrm{Pref}}_{L,\mathcal{C}}$ 通过即停；最多 N 步，否则 $\bot$。
- **性质**：对 $(\Sigma^*, \preceq)$ **扩张、幂等、单调**（典型**闭包算子**）。

2.2 预测后缀闭包（右延直到命中或超上限）

- **定义**：
  $\mathbf{Cl}^{\mathrm{Suf}}_{U,L_p}(s) =$ 按 $\mathbf{R}$ 右延（逐字符/片段），按降序 $U \cap [1..]$ 查最长 $L \le L_p$ 使 $\mathbf{T}^{\mathrm{Suf}}_{L,\mathcal{C}}$ 成立，“命中即停”；否则回退或 $\bot$。

- **性质**：同为**扩张、幂等、单调**的闭包算子。

> 两个闭包与 tests/投影共同给出 **Kleene Algebra with Tests（KAT）** 风格的“while 命中即停”语义。

---

3) 复合算子（业务可直接调用的“流程件”）

3.1 观测构建器（历史窗口）

$$\mathbf{B}_{L_h}(p,\chi) = \mathbf{R}_{\langle \mathrm{eos}\rangle} \circ \mathbf{R}_{\chi} \circ \mathbf{R}_{\langle \mathrm{sep}\rangle} \circ \mathbf{\Pi}_{L_h}(p) \circ \mathbf{R}_{\langle \mathrm{bos}\rangle}$$

> 把“prev 的尾窗 + 分隔 + 当前目标符”拼成单步观测串。

3.2 历史拓扑器（左扩对齐）

$$\mathbf{H}_{U,N} = \mathbf{Cl}^{\mathrm{Pref}}_{U,N} \circ \mathbf{B}_{L_h}$$

> 对 $\mathbf{B}$ 的输出做“前缀最长可用命中”的闭包（控制步数 N）。

3.3 预测拓扑器（命中即停）

$$\mathbf{P}_{U,L_p} = \mathbf{Cl}^{\mathrm{Suf}}_{U,L_p} \circ \mathbf{D}_{\mathrm{head}}$$

> 首位去重后，做“后缀最长可用命中（上限 L_p）”。

3.4 bigram 拓扑器（前向组合）

$$\mathbf{Bi}_{U,L_p}(\chi,\cdot) = \mathbf{Cl}^{\mathrm{Suf}}_{U,L_p} \circ \mathbf{R}_{\chi}$$

> 先右乘当前字符，再做后缀闭包，用于 bigram 奖励与注记。

3.5 法规/医疗等域的强约束管线（KAT 形式）

$$\boxed{\mathbf{F} = \mathbf{T}_{\mathrm{legal}} \ \circ\ \mathbf{H}_{U,N} \ \circ\ \mathbf{T}_{\mathrm{budget}} \ \circ\ \mathbf{P}_{U,L_p} \ \circ\ \mathbf{T}_{\mathrm{clean}}}$$

> **tests（门控）—闭包—tests—闭包—清洗** 的标准序列；每段均可热更。

---

4) 加权评分（半环语义，非必须）

把“隶属度×语义阈×IDF”视为权重半环 S 上的评分：

$$w(s) = \mu(\text{seg}) \ \otimes \ \underbrace{\max(0, \text{sim} - \tau)}_{\text{门控}} \ \otimes \ \text{idf}(\text{seg}), \quad (\oplus = \max,\ \otimes = \times)$$

> 与上面的闭包/tests 结合即形成**带权 Kleene 代数**；用于择优“最长且可信”的命中路径。

---

5) 关键等式法则（优化/融合用）

投影融合（幂等/可交换）

- $\mathbf{\Pi}_L \circ \mathbf{\Pi}_M = \mathbf{\Pi}_{\min(L,M)}$；$\mathbf{Head}_L \circ \mathbf{Head}_M = \mathbf{Head}_{\min(L,M)}$。

乘子融合

- $\mathbf{L}_{h_1} \circ \mathbf{L}_{h_2} = \mathbf{L}_{h_1 \circ h_2}$；
  $\mathbf{R}_{h_1} \circ \mathbf{R}_{h_2} = \mathbf{R}_{h_2 \circ h_1}$。

tests 结合

- $\mathbf{T}_P \circ \mathbf{T}_Q = \mathbf{T}_{P \wedge Q}$（幂等、交换）。

闭包幂等

- $\mathbf{Cl} \circ \mathbf{Cl} = \mathbf{Cl}$（前缀/后缀两类皆然）。

条件交换（工程可判）

- 若 $\mathbf{\Pi}_{L_h}$ 不改变 $\mathbf{Cl}^{\text{Suf}}$ 的停点，则
  $\mathbf{Cl}^{\text{Suf}}_{U,L_p} \circ \mathbf{\Pi}_{L_h} = \mathbf{\Pi}_{L_h} \circ \mathbf{Cl}^{\text{Suf}}_{U,L_p}$。
- 同理对 $\mathbf{Cl}^{\text{Pref}}$ 与 $\mathbf{L}_h$ 存在可判定的可交换前提（裁剪不破坏前缀命中路径）。

---

6) 快速总表（命名对照）

类别	名称	记号	核心性质
左乘	左乘子	$\mathbf{L}_h$	幺半群作用；可合并
右乘	右乘子	$\mathbf{R}_h$	反序合并
裁剪	尾裁剪	$\mathbf{\Pi}_L$	幂等、交换、可与 min 同构
裁剪	首裁剪	$\mathbf{Head}_L$	同上
清洗	CJK 过滤	$\mathbf{CJK}$	幂等
测试	后缀/前缀命中	$\mathbf{T}_{L,\mathcal{C}}^{\mathrm{Suf/Pref}}$	幂等、交换
规范	首位去重	$\mathbf{D}_{\mathrm{head}}$	幂等
闭包	前缀闭包	$\mathbf{Cl}_{U,N}^{\mathrm{Pref}}$	扩张、幂等、单调
闭包	后缀闭包	$\mathbf{Cl}_{U,L_p}^{\mathrm{Suf}}$	扩张、幂等、单调
复合	观测构建	$\mathbf{B}_{L_h}$	右乘链 + 尾裁剪
复合	历史拓扑器	$\mathbf{H}_{U,N}$	$\mathbf{Cl}^{\mathrm{Pref}} \circ \mathbf{B}$
复合	预测拓扑器	$\mathbf{P}_{U,L_p}$	$\mathbf{Cl}^{\mathrm{Suf}} \circ \mathbf{D}$
复合	bigram 拓扑器	$\mathbf{Bi}_{U,L_p}$	$\mathbf{Cl}^{\mathrm{Suf}} \circ \mathbf{R}_\chi$
复合	合规管线	$\mathbf{F}$	tests–闭包–tests–闭包–清洗

一句话落地：把所有流程都归约为“**左/右乘**（拼接）、**投影**（裁剪）、**tests**（门控）与“**闭包**（直到命中/命中即停）”四类元算子；它们在 $\mathrm{End}(\Sigma^*)$ 的**函数合成幺半群**中封闭，且具备可复用的幂等/交换/合并等式，工程侧据此即可做**规则融合、步数削减、可判交换**与**形式验证**。
